



# 语音识别：从入门到精通

## 第二讲：语音信号处理及特征提取

主讲人 孙思宁

博士，毕业于西北工业大学  
ssning2013@gmail.com





# 内容提要

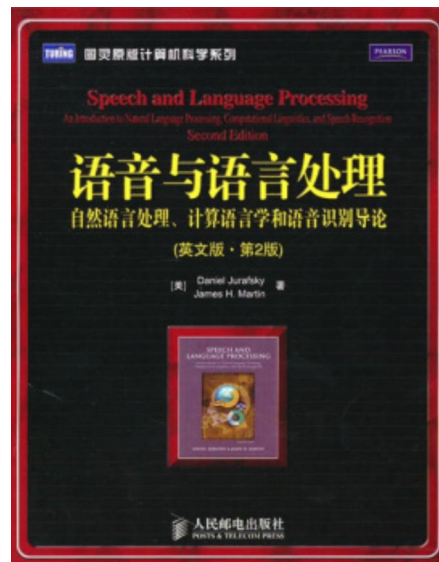

## 1. 数字信号处理基础

- 基础知识
- 傅里叶分析

## 2. 常用特征提取

- 特征提取流程
- Fbank
- MFCC

## 3. 课后实践





[http://www.speech.cs.cmu.edu/15-492/slides/03\\_mfcc.pdf](http://www.speech.cs.cmu.edu/15-492/slides/03_mfcc.pdf)



## ■ 模拟信号到数字信号转化 (ADC)

- 在科学和工程中，遇到的大多数信号都是连续的模拟信号，例如电压随着时间的变化，一天中温度的变化等等，而计算机只能处理离散的信号，因此，必须对这些连续的模拟信号进行转化，通过采样和量化，转换成数字信号。






- 以正弦波为例，理解一些基础定义
  - 考虑一个正弦波 (a)

$$x(t) = \sin(2\pi f_0 t)$$

其中 $f_0$ 表示信号本身的频率，单位为Hz

如果我们对此正弦波进行采样，每隔 $t_s$ 秒进行一次采样，并使用一定范围的离散数值表示采样值，则可以得到采样后的离散信号 (b)

$$x(n) = \sin(2\pi f_0 n t_s)$$





- 离散信号中的定义

$$x(n) = \sin(2\pi f_0 n t_s)$$


其中

$t_s$  为采样周期;

$f_s = 1/t_s$  为采样频率, 或采样率, 表示1s内采样的点数;

$n = 0, 1, \dots$  为离散整数序列

问题: 如果给定一个正弦波采样后的序列, 如 (b),  
可以唯一的恢复出一个连续的正弦波吗?





- 频率混叠



首先，请尝试使用图 (a) 中的采样点画出其对应的连续正弦波

图 (b) 给出了两种可能的画法，也就是说，不同频率的正弦波，经过采样后，完全有可能出现相同的离散信号！为什么？

$$\begin{aligned}x(n) &= \sin(2\pi f_0 n t_s) \\&= \sin(2\pi f_0 n t_s + 2\pi m) \\&= \sin(2\pi(f_0 + \frac{m}{n t_s})t_s)\end{aligned}$$

如果  $m = kn$ ， $k$  为整数，则有

$$x(n) = \sin(2\pi(f_0 + kf_s)t_s)$$






- 奈奎斯特采样定律

采样频率大于信号中最大频率的两倍！

$$f_s/2 \geq f_{\max}$$

即，在原始信号的一个周期内，至少要采样两个点，才能有效杜绝频率混叠问题。



问题1：如果对语音模拟信号进行采样率为16000Hz的采样，得到的离散信号中包含的最大频率是多少？

问题2：对一个采样率为16K的离散信号进行下采样，下采样到8K，为什么要需要首先进行低通滤波？



# 离散傅里叶变换

- 为什么要进行DFT?

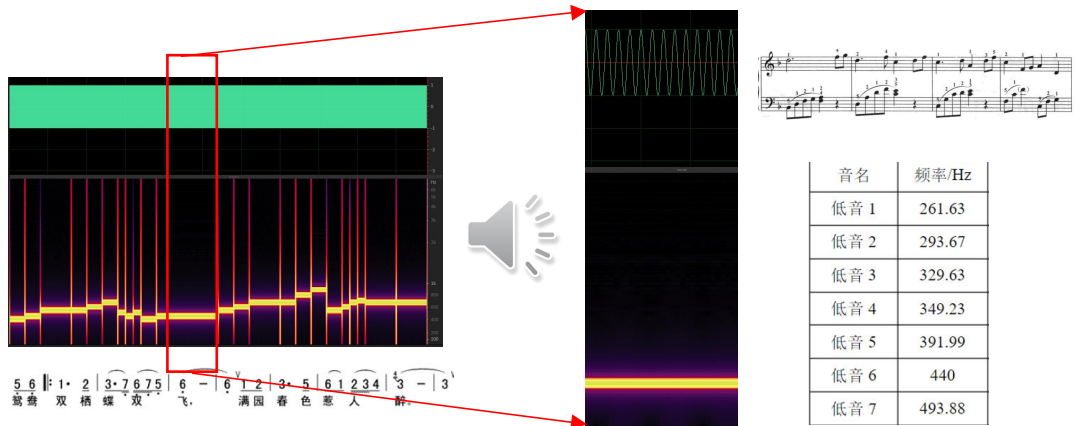

DFT将时域信号变换到频域，分析信号中频率成分

- 什么信号可以进行DFT?

时域离散且周期的信号

- 非周期离散信号可以吗?

需要进行周期延拓







# 离散傅里叶变换





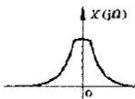
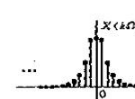
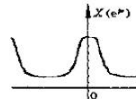

## • 傅里叶家族

傅里叶变换

傅里叶级数

离散时间傅里  
叶变换

离散傅里叶  
变换 (DFT)

	连续 非周期	连续 周期	离散 非周期	离散 周期
时域	 $X(j\Omega) = \int_{-\infty}^{\infty} x(t) e^{-j\Omega t} dt$	 $X(k\Omega_0) = \frac{1}{T} \int_{-\infty}^{\infty} x(t) e^{-jk\Omega_0 t} dt$	 $X(e^{j\omega}) = \sum_{n=-\infty}^{\infty} x(n) e^{-j\omega n}$	 $X(k) = \sum_{n=-\infty}^{\infty} x(n) e^{-j2\pi k n/N}$
频域	 $x(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} X(j\Omega) e^{j\Omega t} d\Omega$ <p>(FT)</p>	 $x(t) = \sum_{k=-\infty}^{\infty} X(k\Omega_0) e^{jk\Omega_0 t}$ <p>(FS)</p>	 $x(n) = \frac{1}{2\pi} \int_{-\pi}^{\pi} X(e^{j\omega}) e^{j\omega n} d\omega$ <p>(DTFT)</p>	 $x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(k) e^{j2\pi k n/N}$ <p>(DFS)</p>
	连续 非周期	离散 非周期	连续 周期	离散 周期

只有DFT是在时域和频域上  
都具有离散和周期的特点，  
因此，也只有DFT可以用计  
算机来处理！

1. 时域上的采样（离散化），导致了频域上的周期，为什么？
2. 时域上的周期，导致了频域上的离散，为什么？



# 离散傅里叶变换

- DFT定义:给定一个长度为 $N$ 的离散信号, DFT定义了 • 根据欧拉公式, DFT的公式还可以为:  
对应的离散频域序列 $X(m)$ 为:

$$X(m) = \sum_{n=0}^{N-1} x(n)e^{-j2\pi nm/N}$$

其中:

$$j = \sqrt{-1},$$

$e$ 为自然对数底

$m$ 频域序列的索引,

$$m = 0, 1, 2, \dots, N-1$$

$X(m)$ 为DFT的第 $m$ 个输出

$$X(m) = \sum_{n=0}^{N-1} x(n) \left[ \cos\left(\frac{2\pi nm}{N}\right) - j \sin\left(\frac{2\pi nm}{N}\right) \right]$$

- DFT本质上是一个线性变换:

$$\begin{bmatrix} X(0) \\ X(1) \\ X(2) \\ \vdots \\ X(N-1) \end{bmatrix} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & e^{-j2\pi/N} & \dots & e^{-j2\pi(N-1)/N} \\ 1 & e^{-j2\pi \cdot 2/N} & \dots & e^{-j2\pi \cdot 2(N-1)/N} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & e^{-j2\pi \cdot (N-1)/N} & \dots & e^{-j2\pi \cdot (N-1)(N-1)/N} \end{bmatrix} \begin{bmatrix} x(0) \\ x(1) \\ x(2) \\ \vdots \\ x(N-1) \end{bmatrix}$$



# 离散傅里叶变换

例题1: 给定信号

$$x(n) = \sin(2\pi \cdot 1000 \cdot nt_s) + 0.5\sin\left(2\pi \cdot 2000 \cdot nt_s + \frac{3\pi}{4}\right), \text{其中 } t_s =$$


$\frac{1}{f_s} = \frac{1}{8000}$ , 给定如下  $N = 8$  个采样点, 计算其傅里叶变换。

$$x(0) = 0.3535, x(1) = 0.3535$$

$$x(2) = 0.6464, x(3) = 1.0607$$

$$x(4) = 0.3535, x(5) = -1.0607$$

$$x(6) = -1.3535, x(7) = -0.3535$$



例题1, DFT之后 $X(m)$ 的幅度



# 离散傅里叶变换

- DFT的性质

性质1. 对称性, 对于实数信号, 有


$$X(m) = X^*(N - m)$$

证明:  $X(N - m) = \sum_{n=0}^{N-1} x(n)e^{-j2\pi n(N-m)/N}$

$$= \sum_{n=0}^{N-1} x(n)e^{-j2\pi nN/N} e^{j2\pi nm/N} = \sum_{n=0}^{N-1} x(n)e^{-j2\pi n} e^{j2\pi nm/N}$$

因为  $e^{-j2\pi n} = \cos(2\pi n) - j \sin(2\pi n) = 1$

故  $X(N - m) = \sum_{n=0}^{N-1} x(n)e^{j2\pi nm/N} = X^*(m)$



例题1, DFT之后X(m)的幅度

此性质很重要, 如上图所示, DFT之后的离散频率序列的幅度具有对称性, 因此, 在进行N点DFT之后, 只需要保留前N/2+1个点。语音信号特征提取时, 一般使用512点DFT, 由于对称性, 我们只需要前257个有效点



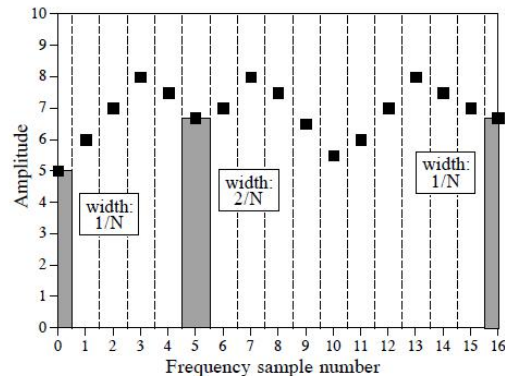
# 离散傅里叶变换

- DFT的性质

性质2:  $X(m)$ 实际上表示的是“谱密度” (spectral density), 如果对一个幅度为A实正弦波进行N点DFT, 则DFT之后, 对应频率上的幅度M和A之间的关系为:

$$M = \frac{AN}{2}$$

可以用例题1进行验证!



DFT之后的频域序列 $X(m)$ 的幅值实际上是一个“密度”的概念, 通俗讲, 即单位带宽上有多少信号存在。



- DFT的性质

性质3: DFT的线性

如果 $x_{\text{sum}}(n) = x_1(n) + x_2(n)$ , 则对应的频域上有:  $X_{\text{sum}}(m) = X_1(m) + X_2(m)$

性质4: 时移性, 对 $x(n)$ 左移 $k$ 个采样点, 得到 $x_{\text{shift}}(n) = x(n - k)$ , 对 $x_{\text{shift}}(n)$ 进行DFT, 有

$$X_{\text{shift}}(m) = e^{\frac{j2\pi km}{N}} X(m)$$



- DFT的频率轴

- 频率分辨率： $f_s/N$ ，表示最小的频率间隔。当N越大时，频率分辨率越高，在频域上，第m个点所表示的分析频率为：

$$f_{\text{analysis}}(m) = \frac{m}{N} f_s$$

从这个角度，我们可以理解为 $X(m)$ 的幅值，体现了原信号中频率成分为 $\frac{m}{N} f_s \text{ Hz}$  的信号强度  
(性质2)

为了提高频率分辨率，我们可以将时域长度为N的信号 $x(n)$ 补0，增加信号的长度，从而提高频率分辨率。对信号进行补0的操作，不会影响DFT的结果，这在FFT（快速傅里叶变换）中和语音信号分析中非常常见。比如，在语音特征提取阶段，对于16k采样率的信号，一帧语音信号长度为400个采样点，为了进行512点的FFT，通常将400个点补0，得到512个采样点，最后只需要前257个点。




- 快速傅里叶变换 (FFT)
  - FFT的基本思想是把原始的N点序列，依次分解成一系列的短序列。充分利用DFT计算式中指数因子 所具有的对称性质和周期性质，进而求出这些短序列相应的DFT并进行适当组合，达到删除重复计算，减少乘法运算和简化结构的目的。
  - 自学FFT算法，推荐教材
    - Understanding DSP，第4章





# Fbank和MFCC特征提取

- Fbank和MFCC (Mel-Frequency Cepstral Coefficients) 提取流程



- Fbank和MFCC特征目前仍是主要使用的特征，虽然有工作尝试直接使用波形建模，但是效果并没有超越基于频域的特征




# Fbank和MFCC特征提取

- Step1. 预加重 (pre-emphasis)


- 提高信号高频部分的能量
- 预加重滤波器是一个一阶高通滤波器，给定时域输入信号 $x[n]$ ，预加重之后的信号为

$$y[n] = x[n] - \alpha x[n - 1]$$

其中,  $0.9 \leq \alpha \leq 1.0$



(a)




(b)



# Fbank和MFCC特征提取

- Step2. 加窗 (windowing) 分帧
  - 语音信号为非平稳信号，其统计属性是随着时间变化的
  - 语音信号又具有短时平稳的属性，在进行语音识别的时候，对于一句话，识别的过程也是以较小的发音单元（音素、字音素或者字、字节）为单位进行识别，因此用滑动窗来提取短时片段
  - 帧长、帧移、窗函数，对于采样率为16kHz的信号，帧长、帧移一般为25ms、10ms，即400和160个采样点





# Fbank和MFCC特征提取

- Step2. 加窗 (windowing) 分帧
  - 分帧的过程，在时域上，即是用一个窗函数和原始信号进行相乘

$$y[n] = w[n]x[n]$$

$w[n]$ 称为窗函数，常用的窗函数有

矩形窗

$$w[n] = \begin{cases} 1, & 0 \leq n \leq L-1 \\ 0, & \text{otherwise} \end{cases}$$

汉明窗

(Hamming)

$$w[n] = \begin{cases} 0.54 - 0.46 \cos\left(\frac{2\pi n}{L}\right), & 0 \leq n \leq L-1 \\ 0, & \text{otherwise} \end{cases}$$



# Fbank和MFCC特征提取

- Step2. 加窗 (windowing) 分帧

- 为什么不直接使用矩形窗?


加窗的过程，实际上是在时域上将信号截断，窗函数与信号在时域相乘，就等于对应的频域表示进行卷积 (\*)，矩形窗主瓣窄，但是旁瓣较大（红色部分），将其与原信号的频域表示进行卷积，就会导致频率泄露。

$$y[n] = w[n]x[n]$$



DFT

$$Y = W * X$$






# Fbank和MFCC特征提取

## • Step3. 傅里叶变换

- 将上一步分帧之后的语音帧，由时域变换到频域，取DFT系数的模，得到谱特征

右图展示了语谱图的生成过程：

1. 加窗分帧
2. 将每一帧信号进行DFT (FFT) , 如第 $t$ 帧信号, DFT系数为 $X_t(m), m = 0, 1, \dots, N$
3. 将每一帧DFT的系数按时间顺序排列, 得到一个矩阵 $Y \in \mathbb{C}^{T \times N}$ , 且 $Y[t, m] = X_t(m)$
4. 语谱图是一个三维图, 横轴表示时间( $t$ ), 纵轴表示频率, 颜色的深浅表示当前时频点上幅度的大小 $|Y[t, m]|$






# Fbank和MFCC特征提取

- Step4. 梅尔滤波器组和对数操作
  - DFT得到了每个频带上信号的能量，但是人耳对频率的感知不是等间隔的，近似于对数函数
  - 将线性频率转换为梅尔频率，梅尔频率和线性频率转换关系

$$\text{mel}(f) = 2595 \log_{10} \left( 1 + \frac{f}{700} \right)$$

- 梅尔三角滤波器组：根据起始频率、中间频率和截止频率，确定各滤波器系数





# Fbank和MFCC特征提取

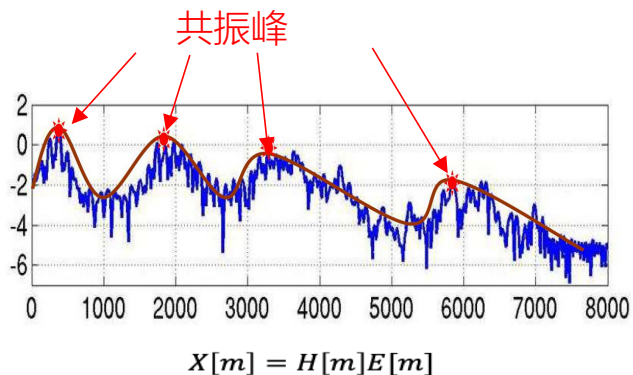
- Step4. 梅尔滤波器组和对数操作
  - 梅尔滤波器组设计
    - 确定滤波器组个数 $P$
    - 根据采样率 $f_s$ , DFT点数 $N$ , 滤波器个数 $P$ , 在梅尔域上等间隔的产生每个滤波器的起始频率、中间频率和截止频率, 注意, 上一个滤波器的中间频率为下一个滤波器的起始频率 (存在overlap)
    - 将梅尔域上每个三角滤波器的起始、中间和截止频率转换线性频率域, 并对DFT之后的谱特征进行滤波, 得到 $P$ 个滤波器组能量, 进行log 操作, 得到Fbank特征
  - MFCC特征在Fbank特征基础上继续进行IDFT变换等操作






# MFCC特征提取

- Step4. 梅尔滤波器组和对数操作
  - 倒谱分析



频域信号可以分解成谱包络(Envelope)和谱细节的乘积，不同音素的谱包络和共振峰具有区分性






# MFCC特征提取

- Step4. 梅尔滤波器组和对数操作
    - 倒谱分析
- $|X[m]| = |H[m]| |E[m]|$
  - $\log|X[m]| = \log|H[m]| + \log|E[m]|$
  - 两边进行IDFT（此处为DCT变换）
  - IDFT之后的第1~K个点，为K维MFCC特征

$$c[k] = \sum_{m=0}^{N-1} (\log|X[m]|) e^{j2\pi mk/N}$$

注意：取log有两个目的：


- 人耳对信号感知是近似对数的，高频部分较为敏感；
- 对数使特征对输入信号的扰动不敏感






# MFCC特征提取

- Step4. 梅尔滤波器组和对数操作
  - IDFT, 对数谱的谱!



IDFT





# MFCC特征提取

- Step5. 动态特征计算

- 一阶差分 (Delta,  $\Delta$ ) , 类比速度, 最简单的一阶差分计算方法

$$\Delta(t) = \frac{c(t+1) - c(t-1)}{2}$$

- 二阶差分 (Delta delta,  $\Delta\Delta$ ) , 类比加速度, 简单计算方法

$$\Delta\Delta(t) = \frac{\Delta(t+1) - \Delta(t-1)}{2}$$

- Step6. 能量计算

$$e = \sum x^2[n]$$



# MFCC特征提取

- MFCC特征总结
  - 一般常用的MFCC特征维39维，包括：
    - 12维原始MFCC
    - 12维 $\Delta$
    - 12维 $\Delta \Delta$
    - 1维能量
    - 1维能量 $\Delta_e$
    - 1维能量 $\Delta \Delta_e$
  - MFCC特征一般用于对角GMM训练，各维度之间相关性小
  - Fbank特征一般用于DNN训练



# 作业

1. 给定一段音频，请提取12维MFCC特征，阅读代码预加重、分帧、加窗部分，完善作业代码中fbank和mfcc部分，并给出最终的Fbank和MFCC特征，用默认的配置参数，无需进行修改。

[https://github.com/nwpuaslp/ASR\\_Course.git](https://github.com/nwpuaslp/ASR_Course.git)

2. 简答课件第7，9页的问题

3. 提交的压缩包请包含如下文件：

其中test.fbank,test.mfcc为程序生成的输出文件

quiz.txt为对课件问题的回答

 mfcc.py	✓
 quiz.txt	✓
 test.fbank	✓
 test.mfcc	✓
 test.wav	✓



## 感谢各位聆听！



西工大音频语音与语言处理研究组